

Predicción del **valor de compra** en Tiendas Duty Free del Aeropuerto de Tocumen

Proyecto Final - Curso
Introducción a la Ciencia de Datos,
Maestría en Analítica de Datos
UTP - II Semestre 2026

GRUPO No. 5

Jorge Gonzalez
Nelson Pimentel
Gerineldo Sousa
Jorge Novarro



Introducción

CONTEXTO

El travel retail está influenciado por el flujo internacional, la estacionalidad, la tienda, la categoría y el perfil del cliente.

PREGUNTA

¿Se puede predecir el valor total de una factura (**TOTAL_FACTURA**) usando variables de tienda, momento de la compra (mes, día de la semana y hora), tamaño de la canasta, clase del producto, género principal de los productos comprados y país del cliente?

HIPÓTESIS

H0: el ticket promedio es igual en las 6 tiendas.

H1: el ticket promedio difiere entre al menos dos tiendas el punto de venta sí influye.

ANOVA confirma diferencias entre tiendas
(**F=1093.51, P≤0**)

LA RIVIERA
DUTY FREE
TOCUMEN INTERNATIONAL AIRPORT



Contexto y Conjunto de Datos

1,102,317 registros

6 Tiendas de Duty Free y cifras de ventas de enero-noviembre 2011, **56** variables

517 devoluciones excluidas


551,431 Facturas positivas como unidad de análisis.

2.48X Razón entre ticket promedio más alto y el más bajo.

Variables relevantes: **tienda, fecha, hora, categoría, género, país, líneas y cantidad total por factura**

Variables excluidas por fuga de datos: correlación > 0.98


MONTO_BRUTO, IMPUESTOS, DESCUENTO, COSTOS



Categorías de Ventas: Fragancias, Cosméticos, Licores, Cigarrillos, Equipo de Viaje y Accesorios.

Análisis Exploratorio Clave

Venta por Tienda



397,667

registros en WISA-03,
la tienda con mayor volumen

21.78M


en ventas totales
en WISA-03

TENDENCIA DE VENTAS MENSUALES



Las ventas crecen de forma sostenida hacia fin de año, con un salto marcado en octubre-noviembre.

VENTAS POR CATEGORÍA





ACCESORIOS Y
COSMÉTICOS

completan las
categorías principales

70.35%

probabilidad del
género femenino en
fragancias

Patrones de Venta por Tiempo y Tienda



38.4%

de las ventas se concentran entre 17:00 y 20:59

F=1093.51

ANOVA confirma diferencias significativas entre tiendas

$p < 10^{-4}$

evidencia estadística robusta

$p < 0.00001$

mayor ingreso en fines de semana

Modelos Usados y Evaluación

LA RIVIERA
DUTY FREE
TOCUMEN INTERNATIONAL AIRPORT

MODELOS COMPARADOS

Regresión Lineal

Lasso (L1) - ($\alpha=0.001$)

Árbol de Decisión - ($\text{max_depth}=12$, $\text{min_split}=5$,
 $\text{min_leaf}=20$)

Random Forest - ($\text{n_estimadores}=120$, $\text{max_depth}=8$)

VALIDACIÓN

División aleatoria 80/20 - 441.1k train/110.3k test

Validación cruzada - 5 fold

Validación temporal (enero-septiembre
entrenamiento, octubre-noviembre prueba)

Baseline y análisis abalación.

MÉTRICAS DE EVALUACIÓN

MAE, RMSE, R^2

Comparación train/test y validación temporal

Modelo	MAE	RMSE	R^2
Regresión Lineal (baseline)			
Lasso (L1)			
Árbol de Decisión			
Random Forest			

Comparación de Modelos de Regresión

MODELO	MAE (\$)	RMSE (\$)	R ²
Random Forest	48.56	177.02	0.253
Árbol de Decisión	56.31	192.47	0.147
Lasso	64.28	199.16	0.061
Regresión Lineal	66.94	201.33	0.039
Baseline promedio tienda	73.95	203.76	0.011

MEJOR MODELO GLOBAL
RANDOM FOREST

48.56	177.02	0.253
MAE (\$)	RMSE (\$)	R ²

BASELINE PROMEDIO TIENDA

73.95	203.76	0.011
MAE (\$)	RMSE (\$)	R ²


RANDOM FOREST MAE (\$) 45.62

enero-septiembre / octubre-noviembre

Impacto de Variables y Rendimiento por Tienda

IMPORTANCIA DE VARIABLES

Aporte relativo al poder predictivo



RENDIMIENTO DEL MODELO POR TIENDA Random Forest

\$ MAE por Tienda (\$)
Error promedio absoluto en dólares. Menor es mejor.



% MAE como % del Ticket Promedio
Error como porcentaje del ticket promedio. Menor es mejor.



La **ablación sin NUM_LINEAS y CANTIDAD_TOTAL** reduce R^2 a 0.139 y aumenta **MAE a \$66.26**
Las variables de tamaño de la canasta son críticas para explicar el valor de compra.

Ablación y ANOVA

El poder predictivo lo define el tamaño de canasta.

Ablación Random Forest

Completo con tamaño de canasta

R^2 0.253 | mejora
13.1%

SIN NUM_LINEAS Y CANTIDAD_TOTAL

R^2 0.139 | mejora 6.7%

El tamaño de canasta domina el poder predictivo.

ANOVA de una vía sobre TIENDA para TOTAL_FACTURA

$F=1093.51$, $p < 0.0001$

Se rechaza H_0 : el ticket promedio difiere entre tiendas

WISA-01

\$125.03

2.48x

WISA-06

\$50.37



Conclusiones

MEJOR MODELO

Random Forest es el mejor modelo para estimar valor durante la transacción

UTILIDAD OPERATIVA

Modelo útil para dimensionamiento de caja y proyección de ingresos

ALCANCE DEL MODELO

No predice anticipadamente el gasto antes de armar la canasta

IMPULSORES CLAVE

Variables de tamaño de compra son clave para el poder predictivo

DESEMPEÑO VARIABLES

Diferencias notables en desempeño según tienda

