

Predicción del Valor de Compra en Tiendas Duty Free — Aeropuerto de Tocumen

Reporte Final — S100 · Introducción a la Ciencia de Datos · Maestría en Analítica de Datos, UTP

Prof. Gabriel Soto, M.Sc. · II Semestre 2026 · Grupo No. 5

Integrantes: Jorge Gonzalez, Nelson Pimentel, Gerineldo Sousa y Jorge Navarro

Resumen ejecutivo

Las seis tiendas Duty Free del Aeropuerto Internacional de Tocumen registran más de un millón de transacciones, con montos de factura muy variables entre sucursales. El proyecto evalúa si el valor de una factura puede predecirse a partir de características de la transacción, y si el punto de venta influye en el comportamiento de compra. Se compararon cuatro modelos de regresión (Lineal, Lasso, Árbol de Decisión y Random Forest) sobre 551,431 facturas, validados con partición aleatoria, validación cruzada, partición temporal, un baseline sencillo utilizando el ticket promedio por tienda y un experimento de ablación. Random Forest fue el mejor modelo ($R^2=0.253$; 13.1% de mejora sobre el baseline), y una prueba ANOVA confirmó que el punto de venta influye significativamente ($p=0$) en el ticket promedio.

1. Introducción

La Riviera Duty Free opera seis tiendas dentro del Aeropuerto Internacional de Tocumen, uno de los hubs de conexión más grandes de Latinoamérica. Cada tienda enfrenta un perfil de pasajero, mezcla de producto y volumen distintos, lo que motiva la pregunta de investigación: ***¿es posible predecir el valor de una transacción a partir de las características observadas durante la compra (tienda, momento, tamaño de la canasta, clase de producto, país del cliente), y el punto de venta específico influye en ese comportamiento de compra?***

Formalizamos esta última pregunta como una hipótesis contrastable: **H0**, el ticket promedio es igual en las seis tiendas; **H1**, el ticket promedio difiere entre al menos dos tiendas (sección 4, Tabla 1). La retroalimentación recibida sobre la versión anterior del white paper señaló que esta hipótesis se mencionaba de forma implícita sin contrastarla formalmente, que faltaba una comparación contra un punto de referencia simple (baseline), que no se distinguía "predecir" de "describir" una factura ya cerrada, y que faltaban métricas de entrenamiento junto a las de prueba. Este reporte incorpora las cuatro correcciones: una prueba de hipótesis formal (ANOVA), un baseline utilizando el ticket promedio por tienda, un experimento de ablación, y métricas de entrenamiento junto a las de prueba (sección 4).

2. Datos y preparación

Fuente: seis archivos CSV (uno por tienda) provistos por el equipo de operaciones de La Riviera Duty Free, consolidados en un único archivo (VentasWisaConsolidado.csv; 1,102,317 filas a nivel de línea de producto, enero–noviembre). Cada fila es un renglón de factura (un producto vendido); se agregó a nivel de FACTURA para obtener el ticket total, generando una tabla de trabajo de 551,431 facturas $\times$ 18 columnas.

Limpieza: La columna NOMBRETIENDA mezclaba tres formatos de texto ("WISA 01", "WISA-03", "WISA MAC") entre los seis archivos de origen; se normalizó en una columna TIENDA con seis valores consistentes (WISA-01...WISA-06). Se excluyeron 517 líneas de devolución (TIPO_DOC=DV) del modelado; el género del producto (DESCRIPCION_GENERO, 1,266 nulos) se imputó por la moda condicionada a la clase de producto. Se descartaron como predictoras MONTO_BRUTO, IMPUESTOS, DESCUENTO, COSTO_UNI y COSTO_TOTAL por su correlación >0.98 con el monto total (misma fórmula contable): usarlas sería una fuga de datos.

Variables finales: numéricas (NUM_LINEAS, CANTIDAD_TOTAL, seno/coseno de mes y hora, fin de semana) y categóricas (TIENDA, día de la semana, clase de producto principal, género principal, país del cliente agrupado).

3. Métodos

Diseño de evaluación: partición aleatoria 80/20 (441,144 / 110,287 facturas) para las métricas principales, validación cruzada de 5 particiones (Lasso y Árbol) y una partición temporal (entrenar enero–septiembre, probar octubre–noviembre) para verificar generalización hacia meses no vistos. Se añadió un baseline ingenuo (promedio histórico de TOTAL_FACTURA por tienda, calculado solo con el set de entrenamiento) y un experimento de ablación (Random Forest sin NUM_LINEAS/CANTIDAD_TOTAL) para separar la capacidad de predicción real de la de simplemente describir una factura ya cerrada.

Modelos comparados: Regresión Lineal (sin regularizar), Lasso (GridSearchCV, $\alpha=0.001$), Árbol de Decisión (GridSearchCV; `max_depth=12`, `min_samples_split=5`, `min_samples_leaf=20`) y Random Forest (RandomizedSearchCV sobre una muestra de 50,000 facturas; `n_estimators=120`, `max_depth=8`, `min_samples_split=2`, `min_samples_leaf=5`). Métricas: error absoluto medio (MAE), raíz del error cuadrático medio (RMSE) y R^2 , reportadas tanto en entrenamiento como en prueba (Tabla 1).

4. Resultados

Tabla 1. Comparación de modelos — métricas de entrenamiento y de prueba (en dólares para MAE/RMSE).

Modelo	Entrenamiento			Prueba		
	MAE	RMSE	R^2	MAE	RMSE	R^2
Baseline (prom. por tienda)	—	—	—	73.95	203.76	0.011
Regresión Lineal	54.41	199.24	0.159	54.61	185.22	0.182
Lasso	54.41	199.24	0.159	54.60	185.22	0.182
Árbol de Decisión	47.32	186.37	0.264	48.74	177.48	0.249
Random Forest	48.17	184.48	0.279	48.56	177.02	0.253

Random Forest obtiene el mejor desempeño de prueba (MAE \$48.56; $R^2=0.253$) y la mayor mejora de RMSE sobre el baseline establecido (13.1%, frente a 12.9% del Árbol y solo 9.1% de los modelos lineales; Tabla 1). La brecha entre entrenamiento y prueba es pequeña en los cuatro modelos (máx. \$1.42 de MAE), sin evidencia de sobreajuste. Un experimento de ablación (retirar NUM_LINEAS y CANTIDAD_TOTAL de Random Forest) muestra que el R^2 cae de 0.253 a 0.139 y la mejora sobre el baseline baja a 6.7%: buena parte del poder predictivo describe una canasta ya armada más que anticipar el gasto antes de la compra (Figura 1).




Figura 1. Importancia de variables — Random Forest y Lasso. El tamaño de la canasta (NUM_LINEAS, CANTIDAD_TOTAL) domina ambos modelos; el género principal del producto también aporta señal real.

Una prueba ANOVA de una vía sobre TOTAL_FACTURA agrupado por TIENDA da $F=1,093.51$ con $p \approx 0$, muy por debajo de 0.05: se rechaza H_0 , y el punto de venta sí influye en el ticket promedio, con una razón de 2.48x entre

la tienda de ticket más alto (WISA-01, \$125.03) y la más baja (WISA-06, \$50.37). Sin embargo, el error del modelo no se reparte igual entre tiendas (Figura 2): el error relativo (MAE/ticket) va de 19% en WISA-06 hasta 57% en WISA-01.




Figura 2. MAE relativo al ticket promedio por tienda (Random Forest, set de prueba).

5. Discusión, limitaciones y conclusión

Los resultados respaldan la hipótesis planteada: la prueba ANOVA rechaza H0 con un margen muy amplio, y la variación del error por tienda (Figura 2) refuerza que las seis sucursales no se comportan igual. Al mismo tiempo, el experimento de ablación matiza esta conclusión — la mayor parte del poder predictivo del modelo completo viene de conocer el tamaño de la canasta una vez iniciada la compra, no de anticipar el gasto a partir del perfil del pasajero y el punto de venta por sí solos.

Limitaciones: el R^2 general (0.253) es modesto — el modelo explica una fracción real pero no dominante de la varianza del ticket; la transformación logarítmica del objetivo no es viable con los modelos lineales sobre este dataset (produce errores no interpretables) y ofrece una mejora solo marginal en los modelos de árboles; y los datos cubren un único período (enero–noviembre), sin poder evaluar estacionalidad de más de un año.

Conclusión: Random Forest es el modelo recomendado (MAE \$48.56; $R^2=0.253$; 13.1% de mejora sobre el baseline), sin evidencia de sobreajuste y con generalización adecuada hacia meses futuros (partición temporal, Tabla 1). El punto de venta es una variable relevante y estadísticamente significativa, aunque el tamaño de la canasta domina la predicción; en producción, el modelo debería complementarse con una evaluación específica por tienda, dado el error elevado en WISA-01.

Referencias

Datos internos: La Riviera Duty Free, Aeropuerto Internacional de Tocumen (VentasDutyFree.csv, seis tiendas, enero–noviembre).

Soto, G. (2026). Syllabus S100 — Introducción a la Ciencia de Datos. Maestría en Analítica de Datos, Universidad Tecnológica de Panamá.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Virtanen, P. et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17, 261–272.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61.

Declaración de uso de inteligencia artificial

Se utilizó un asistente de IA (Claude, Anthropic) como apoyo puntual en tareas específicas: (a) depuración de errores de sintaxis y formato en el pipeline de limpieza y modelado en Python (pandas, scikit-learn, scipy), cuya lógica y decisiones de diseño fueron definidas por el equipo; (b) generación de figuras y tablas de este reporte a partir de los resultados ya obtenidos en el notebook del proyecto; y (c) edición de redacción de este documento. El diseño del proyecto la pregunta de investigación, la hipótesis, qué validaciones adicionales incluir (baseline, ablación, prueba de hipótesis) y la interpretación de cada resultado fue trabajo del equipo. Como alternativa, se consideró prescindir de la IA para estas tareas puntuales de formato y depuración; se optó por usarla para ahorrar tiempo en aspectos repetitivos (formato consistente de gráficas y tablas) y dedicar ese tiempo a análisis e interpretación. Todo el código, los números y las conclusiones fueron revisados y validados por el equipo antes de su entrega.